

Sprawozdanie 10.

Poszukiwanie minimum wartości funkcji metodą największego spadku w 2D

Mirosław Kołodziej

13.05.2021

1. Wstęp teoretyczny

1.1 Kierunkowe metody poszukiwania minimum funkcji

Pochodną kierunkową funkcji celu definiujemy różniczkę zupełną funkcji celu jako iloczyn skalarny wektorów:

$$df = \frac{\partial f}{\partial x_i} dx_1 + \dots + \frac{\partial f}{\partial x_n} dx_n = \nabla f(x) dx.$$

Zakładamy, że wektor \vec{u} wyznacza kierunek prostej łączącej punkty x i x' , możemy więc zapisać:

$$x(\lambda) = x' + \lambda \vec{u},$$

zaś dla bardzo małych zmian wartości λ :

$$dx = \vec{u} d\lambda$$

Na prostej łączącej x i x' funkcję celu, zależną od zmiennej λ wyraża się wzorem:

$$F(\lambda) = f(x' + \lambda \vec{u}) = f(x).$$

Wyliczając różniczkę zupełną dla tej funkcji otrzymujemy:

$$dF = df = \nabla^T f(x) \vec{u} d\lambda,$$

zaś pochodną kierunkową funkcji celu w punkcie x dla kierunku \vec{u} wyrażamy następująco:

$$\frac{dF(\lambda)}{d\lambda} = \left. \frac{df(x)}{d\lambda} \right|_{\vec{u}} = \nabla^T f(x) \vec{u}$$

Korzystając z rozwinięcia w szereg Taylora mamy:

$$F(\lambda) = F(0) + \frac{dF}{d\lambda} \lambda \left(+ \frac{d^2 F}{d\lambda^2} \frac{\lambda^2}{2} + \dots \right) \rightarrow \text{zaniedbujemy},$$

gdzie:

$$F(\lambda) = f(x' + \lambda \vec{u}) = f(x)$$

$$F(0) = f(x' + 0 \cdot \vec{u}) = f(x').$$

Wprowadźmy następujące założenie:

$$\lambda > 0, \quad \frac{dF}{d\lambda} = \nabla^T f(x') \vec{u} = -|\nabla^T f(x') \vec{u}| < 0,$$

wtedy:

$$F(\lambda) = f(x') - \lambda |\nabla^T f(x') \vec{u}| < f(x').$$

Zatem, ze względu określenia gradientu funkcji w dowolnym punkcie, musimy dobrać wektor \vec{u} tak, aby spełniał warunek:

$$\nabla^T f(x') \vec{u} < 0.$$

Rozpoczynając w określonym punkcie x_0 , szukamy kolejnego przybliżenia x_1 w kierunku spadku wartości funkcji. Wyznaczamy tym samym ciąg kolejnych przybliżeń x_0, x_1, x_2, \dots poszukiwanego minimum. Procedurę iteracyjną przerywamy, gdy spełni się jeden z warunków:

- $\|x^{i+1} - x^i\| < \epsilon$
- $\nabla f(x) = \vec{0}$
- w kolejnych iteracjach rośnie wartość normy $\|x^{i+1} - x^i\|$ – oznacza to brak zbieżności.

1.2 Metoda największego spadku

Metoda największego spadku to algorytm numeryczny mający na celu znalezienie minimum zadanej funkcji celu. Korzystamy w niej z pochodnej kierunkowej funkcji w punkcie x' :

$$\left. \frac{df(x')}{d\lambda} \right|_{\vec{u}} = \frac{dF(\lambda)}{d\lambda} = \nabla^T f(x') \vec{u},$$

gdzie długość wektora kierunkowego \vec{u} to $\|\vec{u}\| = 1$. Korzystając z nierówności Schwartza:

$$\nabla^T f(x') \vec{u} \geq -\|\nabla^T f(x')\| \cdot \|\vec{u}\| = \geq -\|\nabla^T f(x')\| \cdot 1.$$

Gdy wybierzemy wektor kierunkowy w poniższej postaci:

$$\vec{u} = \frac{-\nabla f(x')}{\|\nabla f(x')\|}$$

to wskazuje on kierunek największego spadku. Pochodna kierunkowa ma wtedy największą wartość:

$$\frac{dF(\lambda)}{d\lambda} = -\nabla^T f(x') \frac{\nabla f(x')}{\|\nabla f(x')\|} = -1.$$

Sam algorytm metody największego spadku możemy przedstawić w postaci:

- wybierz x^0
- obliczaj iteracyjnie:

$$\vec{u}^i = \frac{-\nabla f(x^{i-1})}{\|\nabla f(x^{i-1})\|}$$

$$x^i = x^{i-1} + \lambda \vec{u}^i$$

$$F(\lambda_i) = f(x^{i-1} + \lambda_i \vec{u}^i) = \min_{\lambda} f(x^{i-1} + \lambda_i \vec{u}^i)$$

- warunki zakończenia obliczeń:

$$\begin{aligned}\|x^{i+1} - x^i\| &< \varepsilon_1 \\ \|\nabla f(x^i)\| &< \varepsilon_2 \\ |f(x^i) - f(x^{i-1})| &< \varepsilon_3\end{aligned}$$

2. Problem

Zadaniem naszych zajęć laboratoryjnych było wyznaczenie numerycznie minimum funkcji:

$$f(\vec{r}) = f(x, y) = \frac{5}{2}(x^2 - y)^2 + (1 - x)^2.$$

Korzystaliśmy przy tym z metody największego spadku. Zaczynaliśmy od przybliżenia \vec{r}_0 , którego wartości w kolejnych iteracjach zmienialiśmy według wzoru:

$$\vec{r}_{i+1} = \vec{r}_i - h \cdot \nabla f(\vec{r})|_{\vec{r}=\vec{r}_i},$$

gdzie gradient $\nabla f(\vec{r})$ jest równy:

$$\nabla f(\vec{r}) = \left[\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right].$$


Zaczęliśmy od zaprogramowania metody największego spadku dla dwóch wymiarów. Pochodne obliczyliśmy numerycznie z poniższych wzorów:

$$\begin{aligned}\frac{\partial f(\vec{r})}{\partial x} &= \frac{f(\vec{r} + \Delta \cdot \vec{e}_x) - f(\vec{r} - \Delta \cdot \vec{e}_x)}{2\Delta} \\ \frac{\partial f(\vec{r})}{\partial y} &= \frac{f(\vec{r} + \Delta \cdot \vec{e}_y) - f(\vec{r} - \Delta \cdot \vec{e}_y)}{2\Delta},\end{aligned}$$

gdzie \vec{e}_x i \vec{e}_y są wersorami układu kartezjańskiego. Przyjeliśmy $\Delta = 10^{-4}$. Następnie szukaliśmy przybliżonego położenia minimum funkcji startując od punktu $\vec{r}_0 = [-0.75, 1.75]$. Przyjeliśmy $h = 0.1$, jako warunek stopu $\|\vec{r}_{i+1} - \vec{r}_i\|_2 < \varepsilon$, a jako maksymalną liczbę iteracji 1000. Obliczenia wykonaliśmy dla $\varepsilon = 10^{-2}$ i $\varepsilon = 10^{-3}$, a wyniki zapisaliśmy do pliku Dla każdej wartości ε sporządziliśmy rysunek, na którym widoczny był kontur funkcji oraz kolejne przybliżenia minimum połączone linią. Skorzystaliśmy przy tym z Gnuplota.


3. Wyniki

3.1 Kontur funkcji z kolejnymi przybliżeniami minimum dla $\varepsilon = 10^{-2}$



Ostateczne przybliżenie minimum wynosi $(0.904394, 0.801381)$.

3.2 Kontur funkcji z kolejnymi przybliżeniami minimum dla $\varepsilon = 10^{-3}$



Ostateczne przybliżenie minimum wynosi $(0.949205, 0.621386)$.

4. Wnioski

Znaleźliśmy minimum wartości funkcji metodą największego spadku w 2D. Algorytm podał niedokładne wartości przybliżeń. Dla przypadku z większą ilością iteracji, wartości te zaczynają oscylować. Możemy więc uznać, że w pierwszym przypadku warunek stopu został obrany zbyt restrykcyjnie – wartości są zbyt dalekie od minimum, w drugim zaś jest on nie do końca właściwy, ze względu na oscylacje. Uzyskane przybliżenie jest dalekie od dokładnego ze względu na kształt funkcji. Kontur wartości funkcji celu jest wydłużony – ma kształt elipsy. Z tego powodu na końcu drugiego rozwiązania możemy zaobserwować zygzak. Mogliśmy otrzymać niedokładne rozwiązania również z powodu braku regulacji wartości h . Zmienianie tej wartości pozwoliłoby na zwiększenie dokładności metody.